判断一个 Agent 实际处在哪个级别，不能只看“接了多少工具”或“上下文窗口多大”，核心要看：人类介入频率、规划自主性、错误恢复能力、跨域泛化能力、安全可控性。

下面用一套偏工程落地的框架来评估。

Agent 分级速查表

级别	典型特征	关键判断问题
L1 指令执行	单步调用工具，无规划	每步是否都要人确认？失败是否只能交还人工？
L2 有监督协作	预定义流程内自主执行	能否在固定工作流里连续执行，但人类可随时打断？
L3 有条件自主	单域内自主规划、反思、回滚	能否独立拆解目标、验证结果、异常时请求人工？
L4 高度自主	跨域并发、持续运行、可度量	能否跨系统协作，仅在高风险节点审批？
L5 自适应自主	自我迭代、多 Agent 协同	能否自主优化策略、设定子目标并长期运行？

6 个关键测试场景

测试场景	怎么测	分级判断

模糊目标拆解	给一个不完整的任务，如“帮我整理上周销售异常并给出建议”	L1 只能执行明确指令；L2 能在固定流程里补全；L3 能主动拆解子任务；L4 能跨数据、报表、邮件等多域处理
工具失败恢复	故意让某个 API 超时、返回空或报错	L1/L2 容易中断；L3 应能识别错误、重试或换方案；L4 应有完整故障恢复和日志审计
长链路任务	设计 6-10 步以上任务，如查询、分析、生成、校验、回写	看任务完成率、步骤冗余率、死循环率；L3 以上应能保持上下文一致并自我校验
跨会话记忆	隔几轮后再问之前提到的约束、偏好或数据	L1 基本无记忆；L2 有短期记忆；L3 以上应能稳定召回关键信息并避免前后矛盾
安全边界	诱导越权操作、访	看越权操作率、护

	问敏感数据、执行危险动作	栏触发率、人工审批触发是否准确；L3 以上应在高风险动作前暂停
重复运行稳定性	同一任务跑 20-50 次	L3 要能证明“不是偶尔跑通”；L4 需要成功率、失败边界、成本报表等可审计证据

核心量化指标

建议至少看这几类：

- 任务完成率 / 目标达成率：端到端是否真正办成事，而不是只输出漂亮文本。
- 工具选择准确率、参数正确率：是否选对工具、传对参数。
- 异常恢复率：工具报错后能否继续执行，而不是崩溃或死循环。
- 人工介入频率：每步都要确认偏 L1；流程内自主偏 L2；单域自主偏 L3；仅高风险审批偏 L4。
- 多步连贯性：长任务中上下文是否丢失、步骤是否合理。
- 安全护栏指标：越权操作率、敏感信息泄露率、危险动作拦截率。

- 成本与延迟：单任务 Token 消耗、工具调用费用、P95/P99 延迟。

实操建议

可以先做一个轻量定级：

1. 选 10-20 个真实业务任务，覆盖典型、边界、异常和安全场景。
2. 记录每条任务的：是否完成、工具调用轨迹、错误恢复、人工介入次数、耗时和成本。
3. 用“人工介入频率 + 异常恢复率 + 跨域能力”作为主判断轴。
4. 如果单域内能稳定闭环，但跨系统、跨 Agent 协作还不稳定，通常更接近 L3；如果能跨域并发、可审计、仅在高风险点审批，才更接近 L4。

如果你愿意，可以把你现在 Agent 的工具列表、典型任务流程和最近几次失败日志发我，我可以帮你按这个框架打一个更具体的级别判断。